

IVADO - EquiAlgo

Bastien Jallais

SOMMAIRE

01. Context et constat

02. Audit


03. Notre solution

04. Conclusion

Context et constat

Approche expérimentale plutôt que théorique

- Différence d'octroi de bourse de +21 points
- Candidats des régions éloignées ont une côte R légèrement plus basse (-0,7 point)
- Rapport de cote éloigné : 0,137 (à cote R, programme, revenu, heure de travail, statut de 1^{er} génération)




Quelle part des 21 points est expliqué ?

Audit

Chiffre la pénalité et la règle du comité


- Candidat éloignée (rapport de cotes $\approx 0,14$). C'est l'équivalent de 1,4 point de cote R retiré.
- Un revenu familial deux fois plus élevé vaut environ 0,9 point de cote R. Le comité avantage les familles aisées.
- Chaque heure travaillée par semaine vaut environ 0,15 point de cote R. Le comité valorise les étudiants qui travaillent pendant leurs études.



Nb de variables	Meilleure combinaison	AUC	Gain vs ligne précédente
1	Heures de travail	0.803	+0.000
2	Revenu + Heures de travail	0.830	+0.027
3	Revenu + Heures de travail + 1re génération	0.839	+0.009
4	Revenu + Heures de travail + 1re génération + Programme	0.845	+0.006
5	Cote R + Revenu + Heures de travail + 1re génération + Programme	0.847	+0.002

Audit

Distribution des heures de travail par région administrative (normalisée)



Variable	AUC	Effet sur la décision, à région égale	Décision
code_postal_3	1,00	copie exacte de la région	exclue du modèle
distance_domicile_campus_km	1,00	aucun	exclue : proxy pur
heures_travail_semaine	0,81	positif, identique dans les deux groupes	conservée : travailler pendant ses études est un mérite légitime
revenu_familial_estime	0,69	positif : avantage légèrement les familles aisées	neutralisée : critère inéquitable pour une bourse, et proxy
premiere_generation_universitaire	0,59	nul	conservée, sans effet
cote_r_equivalent	0,56	critère principal	conservée
programme_etudes	0,55	négligeable	conservée

Remarque sur le projet

- Le même modèle est utilisé pour évaluer à la fois les demandes de bourses d'excellence et les demandes de prêts d'études.
- Or, ces deux programmes ne poursuivent pas le même objectif éthique :
 - Bourse d'excellence : récompenser les étudiants ayant les meilleurs résultats ou le plus grand potentiel.
 - Prêt d'études : soutenir les étudiants ayant un besoin financier plus important afin de leur permettre d'entreprendre ou de poursuivre leurs études.
- Il serait donc pertinent de créer deux modèles distincts, chacun adapté aux objectifs spécifiques du programme qu'il évalue.
- Cette séparation permettrait de prendre des décisions plus cohérentes avec les objectifs de chaque programme et pourrait, par conséquent, contribuer à réduire certains biais.

Audit




Parité démographique



Égalité des chances (retenue)

Question	Chaque groupe reçoit-il le même pourcentage de bourses ?	Parmi ceux qui méritent la bourse, chaque groupe a-t-il la même chance de l'obtenir ?
Tient compte du mérite	Non	Oui
Risque	Accorder des quotas, refuser des candidats plus méritants	Dépend de la définition du mérite

Model solution - Treshold




Model solution

Le modèle en bref

- On entraîne sur les 10 000 décisions historiques, avec la cote R, le log du revenu, les heures travaillées, la première génération, le programme et l'indicateur région éloignée
- On met région éloignée à 0 et on remplace le revenu par la médiane. Chaque candidat est donc classé comme s'il venait d'un centre avec le même revenu.
- Les 40 % meilleurs scores reçoivent la bourse, ce qui respecte le budget (36–44 %)
- Le code postal et la distance étant des proxys purs sont retiré

Model solution



Plan de surveillance

#	Indicateur	Fréquence	Seuil d'alerte	Source
1	Taux d'octroi global	chaque cohorte	hors de 36–44 %	surveillance.py
2	Écart de taux d'octroi centres – régions éloignées	chaque cohorte	> 5 points	surveillance.py
3	Ratio des 4/5 (taux du groupe le moins favorisé ÷ taux de l'autre)	chaque cohorte	< 0,80	surveillance.py
4	Taux d'octroi de chacune des 5 régions	chaque cohorte	une région à plus de 8 points de la moyenne	surveillance.py
5	Dérive des variables (PSI : cote R, heures, revenu, distance)	chaque cohorte	PSI > 0,20	surveillance.py
6	Part des régions éloignées parmi les demandes	chaque cohorte	variation > 20 %	surveillance.py
7	Écart d'égalité des chances, mesuré sur un échantillon d'audit indépendant	annuelle	> 0,05	panel indépendant
8	Taux de recours et de décisions renversées, par région	trimestrielle	un groupe à plus du double de l'autre	registre des recours
9	Réussite des boursiers (diplomation, maintien de la bourse), par région	annuelle	écart > 5 points à cote R comparable	registre académique